PROYECTO
EDA

AUTORA: PATRICIA ROMO JIMÉNEZ

Contenido

1. Introducción 3
1.1. Contexto 3
1.2. Objetivo del análisis 3
1.3. Alcance del proyecto 3
2. Descripción del Dataset 3
2.1. Origen de los datos 3
2.2. Diccionario de variables 5
2.2.1. Variables originales del dataset de campañas 5
2.2.2 Variables originales del dataset de detalle del cliente 6
2.2.3 Variables geográficas 6
2.2.4 Variables auxiliares de limpieza 6
2.2.5 Variables temporales derivadas 6
2.2.6 Variables derivadas sobre composición del hogar 6
3. Metodología 7
3.1. Entorno de trabajo 7
3.2. Flujo de trabajo con Git 8
3.3. Fases del proyecto 8
4. Limpieza y transformación 9
4.1. Exploración inicial 9
4.2. Tratamiento de valores nulos 10
4.3. Eliminación de duplicados 11
4.4. Conversión de tipos de datos 11
4.5. Creación de nuevas variables (Feature Engineer) 12
4.6. Dataset final limpio 13
5. EDA y visualización 14
5.1. Enfoque del análisis exploratorio 14
5.2. Análisis descriptivo 15
5.3. Visualización de los datos 15
5.4. Principales hallazgos del EDA 16
5.5. Relación entre EDA y dashboard final 17
6. Modelo de Machine Learning 17
6.1. Objetivo del modelo 17
6.2. Selección de variables 17
6.3. División del dataset (train/test) 19
6.4. Entrenamiento del modelo 19
6.5. Evaluación del modelo 20
6.6. Interpretación de resultados 22
7. Dashboard en Power BI 22
7.1. Objetivo del dashboard 22
7.2. Visualización 23
7.3. Interpretación de los resultados 23

8. Resultados e insights clave 24
8.1. Hallazgos principales 24
8.2. Factores que influyen en la contratación del depósito 24
8.3. Posibles aplicaciones prácticas 25
9. Conclusión 26
10. Anexos 26
10.1. Fragmentos de código relevantes 26
11. Bibliografía y recursos utilizados 27

1. Introducción

1.1. Contexto

En el sector bancario, las campañas de marketing directo permiten promocionar productos financieros a clientes potenciales a través de distintos canales de contacto. En este caso, el proyecto se centra en el análisis de campañas telefónicas realizadas por una institución bancaria portuguesa, cuyo objetivo era lograr la suscripción de un depósito a plazo. El proyecto parte de dos fuentes de datos: un primer dataset con información sobre las campañas, las interacciones realizadas y el contexto económico, y un segundo dataset con variables demográficas y de comportamiento de los clientes, como ingresos, composición del hogar y visitas web mensuales.

El análisis de este tipo de datos resulta útil para comprender mejor qué factores se asocian con la contratación del producto y para apoyar la toma de decisiones en futuras campañas comerciales.

1.2. Objetivo del análisis

El objetivo principal de este proyecto es realizar un **Análisis Exploratorio de Datos (EDA) con Python** para estudiar los factores que influyen en que un cliente suscriba o no un depósito a plazo, tal y como se establece en el enunciado del proyecto.

Para ello, se ha llevado a cabo un proceso completo que incluye la **unión de las distintas fuentes de datos**, la **limpieza y transformación del dataset**, el **análisis descriptivo de las variables**, la **visualización de patrones y relaciones relevantes** y, como ampliación, la construcción de un **modelo sencillo de Machine Learning** para comprobar hasta qué punto algunas variables permiten predecir la suscripción del depósito

1.3. Alcance del proyecto

El proyecto abarca varias fases. En primer lugar, se realiza la preparación del dato, incluyendo la unión de las tres hojas del archivo de clientes con el dataset principal, el tratamiento de valores nulos, la conversión de tipos de datos y la creación de nuevas variables derivadas para enriquecer el análisis. A continuación, se desarrolla un análisis exploratorio centrado en la variable objetivo y en bloques de variables demográficas, de campaña y económicas, con el fin de identificar patrones de comportamiento y diferencias entre los clientes que sí contratan el depósito y los que no.

Además, se incorpora una fase de **Machine Learning** mediante un modelo básico de regresión logística para predecir la contratación del depósito y evaluar su comportamiento. Finalmente, los resultados principales se sintetizan mediante visualizaciones y un **dashboard en Power BI**, con el objetivo de presentar de forma clara los hallazgos más relevantes del proyecto.

2. Descripción del Dataset

2.1. Origen de los datos

Estos conjuntos de datos están relacionados con campañas de *marketing* directo de una institución bancaria portuguesa. Las campañas de marketing se basaron en llamadas telefónicas. A menudo, se requería más de un contacto con el mismo cliente para determinar si el producto (depósito a plazo bancario) sería suscrito o no.

- Bank additional

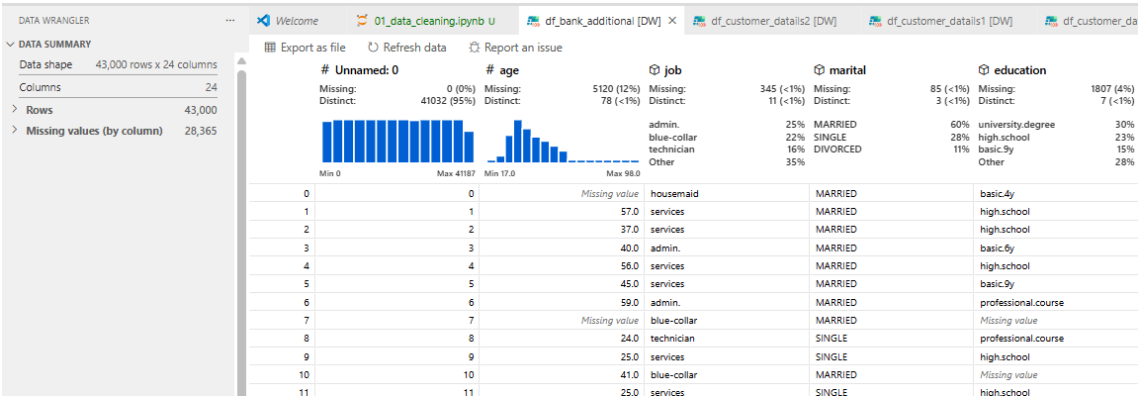

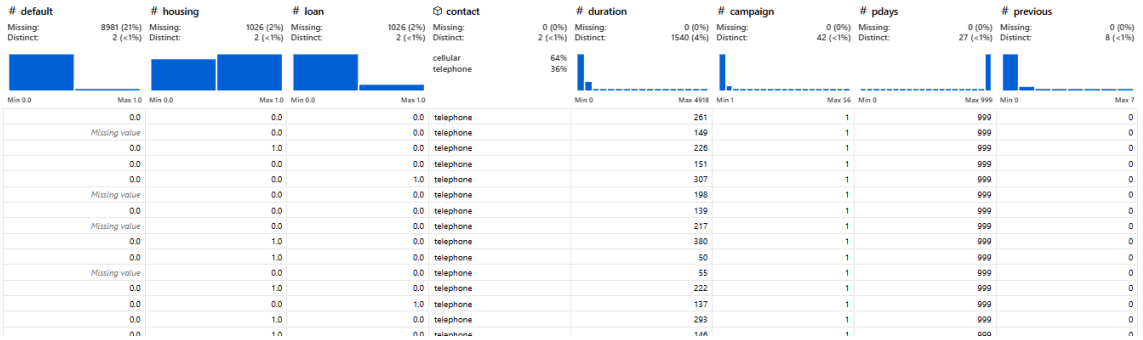

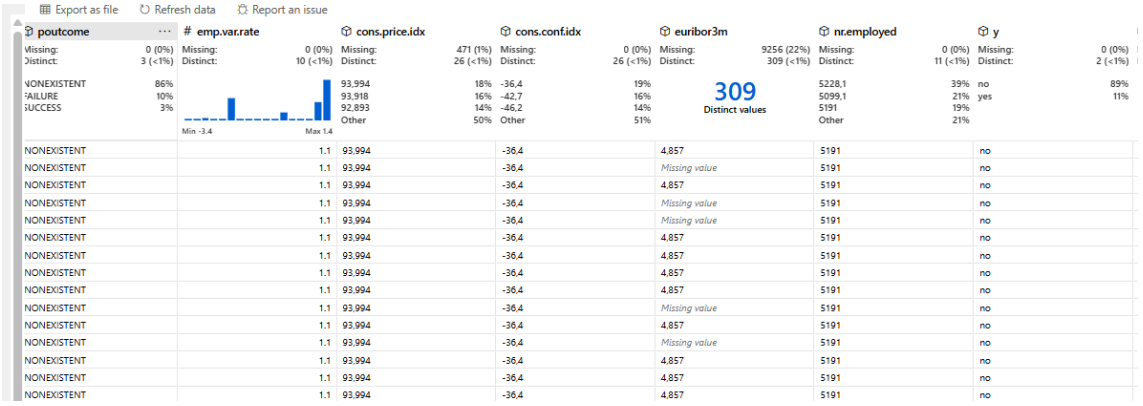

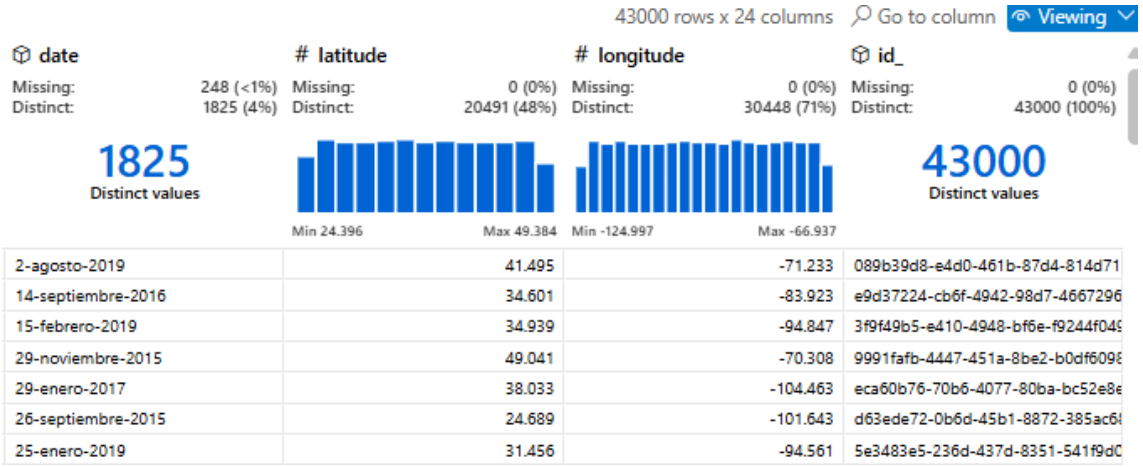

- Customer datails

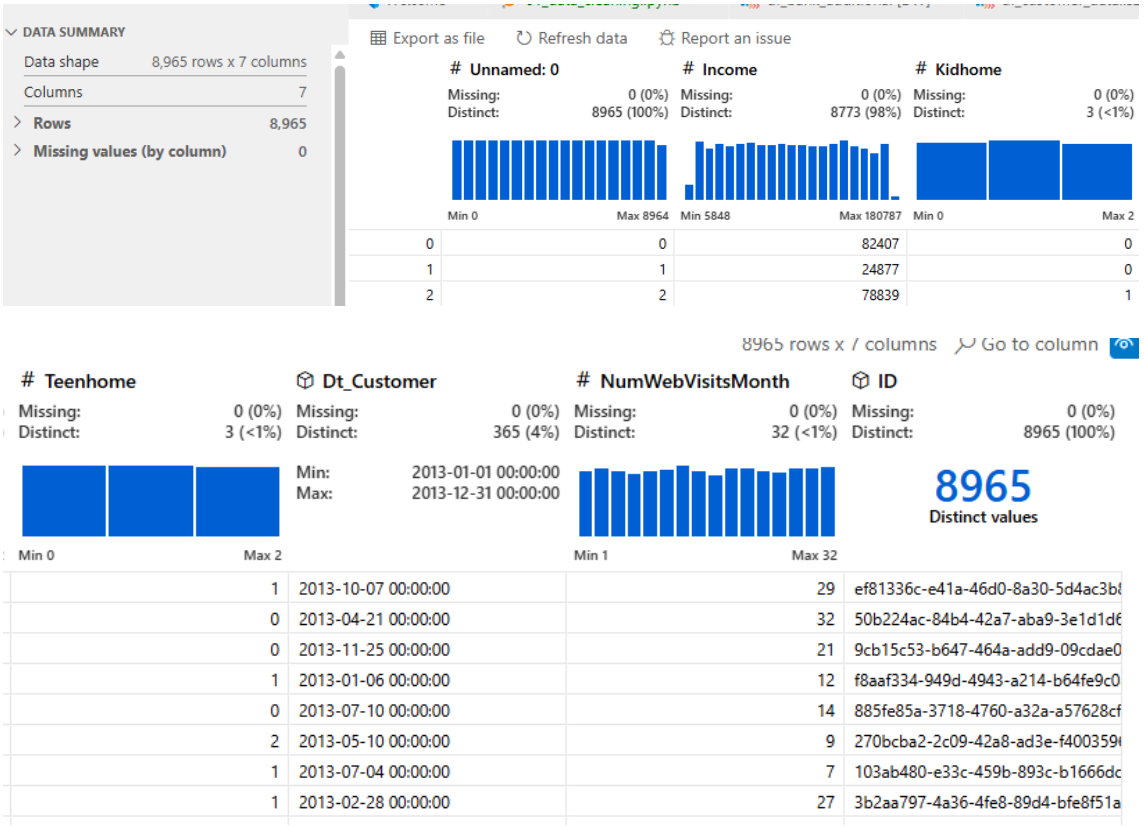

El segundo set de datos (**'customer-details.xlsx'**) es un archivo Excel que nos da información sobre las características demográficas y comportamiento de compra de los clientes del banco. Este Excel consta de 3 hojas de trabajo diferentes, en cada una de ellas tenemos los clientes que entraron en el banco en diferentes años.

2.2. Diccionario de variables

A continuación se presenta el diccionario de variables utilizado en el proyecto. El dataset final integra información de campañas de marketing bancario, variables demográficas del cliente y variables derivadas creadas durante el proceso de limpieza y transformación. Las variables originales incluidas en el proyecto son las definidas en el enunciado del dataset de campañas y del fichero de detalle de clientes.

2.2.1. Variables originales del dataset de campañas

- **age**: edad del cliente.
- **job**: ocupación o profesión del cliente.
- **marital**: estado civil del cliente.
- **education**: nivel educativo del cliente.
- **default**: indica si el cliente tiene historial de impago.
- **housing**: indica si el cliente tiene préstamo hipotecario.
- **loan**: indica si el cliente tiene otro tipo de préstamo.
- **contact**: método de contacto utilizado en la campaña.
- **duration**: duración, en segundos, de la última llamada o interacción.
- **campaign**: número de contactos realizados durante la campaña actual para ese cliente.
- **pdays**: número de días transcurridos desde el último contacto con el cliente.

- **previous**: número de contactos realizados con el cliente antes de la campaña actual.
- **poutcome**: resultado de la campaña de marketing anterior.
- **emp.var.rate**: tasa de variación del empleo.
- **cons.price.idx**: índice de precios al consumidor.
- **cons.conf.idx**: índice de confianza del consumidor.
- **euribor3m**: tipo de interés Euribor a 3 meses.
- **nr.employed**: número de empleados.
- **y**: variable objetivo; indica si el cliente suscribe o no el depósito.
- **date**: fecha en la que se realizó la interacción con el cliente.
- **contact_month**: mes en el que se realizó la interacción.
- **contact_year**: año en el que se realizó la interacción.
- **id_**: identificador único del registro.

2.2.2 Variables originales del dataset de detalle del cliente

- **Income**: ingreso anual del cliente.…
- **Kidhome**: número de niños en el hogar del cliente.
- **Teenhome**: número de adolescentes en el hogar del cliente.
- **Dt_Customer**: fecha en la que el cliente se convirtió en cliente del banco o empresa.
- **NumWebVisitsMonth**: número de visitas mensuales del cliente a la web.

2.2.3 Variables geográficas

- **latitude**: latitud asociada al registro del cliente.
- **longitude**: longitud asociada al registro del cliente.

2.2.4 Variables auxiliares de limpieza

- **age_missing**: indicador de si el valor de edad estaba originalmente ausente y fue tratado durante la limpieza.
- **euribor_missing**: indicador de si el valor de Euribor estaba originalmente ausente y fue tratado durante la limpieza.

2.2.5 Variables temporales derivadas

- **contact_weekday**: día de la semana en que se realizó el contacto.
- **was_contacted_before**: indicador de si el cliente había sido contactado anteriormente.
- **Customer_year**: año de alta del cliente.
- **Customer_month**: mes de alta del cliente
- **Customer_tenure_years**: antigüedad del cliente en años.
- **tenure_at_contact_days**: antigüedad del cliente en días en el momento del contacto.

2.2.6 Variables derivadas sobre composición del hogar

- **Family_size**: tamaño estimado de la unidad familiar del cliente.
- **Has_kid**: indicador de presencia de niños en el hogar.
- **Has_teens**: indicador de presencia de adolescentes en el hogar.

2.3. *Dataset final limpio*

```
<class 'pandas.DataFrame'>
RangeIndex: 42752 entries, 0 to 42751
Data columns (total 41 columns):
 #   Column                  Non-Null Count  Dtype
---  ------                  --------------  -----
 0   age                     42752 non-null  float64
 1   job                     42752 non-null  str
 2   marital                 42752 non-null  str
 3   education               42752 non-null  str
 4   default                 42752 non-null  str
 5   housing                 42752 non-null  str
 6   loan                    42752 non-null  str
 7   contact                 42752 non-null  str
 8   duration                42752 non-null  int64
 9   campaign                42752 non-null  int64
 10  pdays                   1577 non-null   float64
 11  previous                42752 non-null  int64
 12  poutcome                42752 non-null  str
 13  emp.var.rate            42752 non-null  float64
 14  cons.price.idx          42752 non-null  float64
 15  cons.conf.idx           42752 non-null  float64
 16  euribor3m               42752 non-null  float64
 17  nr.employed             42752 non-null  float64
 18  y                       42752 non-null  int64
 19  date                    42752 non-null  str
...
 39  Customer_tenure_years   42752 non-null  float64
 40  tenure_at_contact_days  42752 non-null  float64
dtypes: float64(13), int64(16), str(12)
memory usage: 13.4 MB
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...
```

3. Metodología

El desarrollo del proyecto se llevó a cabo siguiendo una metodología estructurada basada en el uso de **Git como sistema de control de versiones**, con el objetivo de simular un entorno de trabajo profesional y mantener una organización clara del código y las distintas fases del análisis.

Se adoptó una estrategia de trabajo basada en ramas (branching strategy), que permite separar cada fase del proyecto y facilitar la integración progresiva de los resultados

3.1. *Entorno de trabajo*

El proyecto se ha desarrollado en un entorno de trabajo orientado al análisis de datos con Python, utilizando herramientas y librerías específicas para cada fase del proceso. La elección de este entorno responde tanto a los requisitos del proyecto como a la necesidad de trabajar de forma estructurada, reproducible y profesional.

Herramientas utilizadas

- **Python 3.11**
  Se ha utilizado como lenguaje principal del proyecto por su flexibilidad y por su amplio ecosistema de librerías para análisis de datos.
- **Pandas**
  Se ha empleado para la carga, limpieza, transformación, combinación y análisis

de los datasets. Ha sido la librería principal para trabajar con tablas de datos y realizar operaciones como filtros, agregaciones, merges y creación de nuevas columnas.

- **Matplotlib y Seaborn**
  Se han usado para la visualización de los datos durante el Análisis Exploratorio de Datos (EDA), generando gráficos que permiten estudiar distribuciones, relaciones entre variables y patrones relevantes.
- **Scikit-learn**
  Se ha empleado en la fase de Machine Learning para construir y evaluar un modelo sencillo de regresión logística orientado a predecir la suscripción del depósito.
- **Jupyter Notebook**
  Ha sido el entorno principal de desarrollo, ya que permite combinar código, salidas, gráficos y explicaciones en un mismo documento. Esto facilita tanto el trabajo por fases como la documentación del proceso.
- **Power BI**
  Se ha utilizado para la creación del dashboard final, con el objetivo de presentar de forma visual y sintética los resultados más relevantes del análisis.
- **Anaconda**
  Se ha usado para la gestión del entorno virtual y de las dependencias del proyecto, garantizando que el trabajo se desarrollara en un entorno controlado y reproducible.

Organización del entorno de trabajo

Para mantener una estructura clara, el proyecto se organizó en varias carpetas:

- **data/raw/**: almacenamiento de los datos originales sin modificar.
- **data/processed/**: almacenamiento del dataset limpio y transformado.
- **notebooks/**: desarrollo por fases mediante notebooks diferenciados.
- **reports/**: almacenamiento de figuras exportadas e informe final.
- **dashboard/**: archivo del dashboard elaborado en Power BI.

Esta organización ha permitido separar cada parte del proyecto y mantener un flujo de trabajo más ordenado, comprensible y fácil de revisar.

3.2. Flujo de trabajo con Git

El control de versiones se gestionó mediante Git, adoptando una estrategia de trabajo basada en ramas (*branching strategy*), con el objetivo de estructurar el desarrollo por fases y mantener una versión estable del proyecto en todo momento.

La estructura utilizada fue la siguiente:

```
main
└── dev
    ├── feature/data-cleaning
    ├── feature/eda-analysis
    ├── feature/machine-learning
```

└── feature/report

La función de cada rama fue:

- **main**: contiene la versión final estable del proyecto, lista para entrega.
- **dev**: rama de integración donde se consolidan las distintas funcionalidades antes de su paso a la versión final.
- **feature/data-cleaning**: desarrollo de la limpieza y transformación de datos.
- **feature/eda-analysis**: implementación del análisis exploratorio y estadístico.
- **feature/ml-dashboard:**construcción y evaluación del modelo de Machine Learning, así como para la parte final de visualización y dashboard explicativo.
- **feature/report**: redacción del informe técnico y documentación final.

Este flujo permite aislar cada fase del desarrollo, minimizar errores y facilitar la integración progresiva del trabajo realizado.

3.3. Fases del proyecto

El proyecto se estructuró en cuatro fases principales:

- **Fase 1. Limpieza y transformación de datos**
  En esta etapa se cargaron y unificaron las distintas fuentes de datos, se trataron valores nulos y duplicados, se revisaron los tipos de datos y se crearon nuevas variables derivadas. El objetivo fue obtener un dataset limpio y preparado para el análisis.

- **Fase 2. Análisis Exploratorio de Datos (EDA)**
  Una vez preparado el dataset, se realizó el análisis exploratorio para estudiar la distribución de las variables, analizar la variable objetivo, detectar patrones y relaciones entre variables, y extraer conclusiones sobre los factores asociados a la suscripción del depósito.

- **Fase 3. Modelo de Machine Learning**
  Como ampliación del proyecto, se construyó un modelo sencillo de regresión logística para predecir si un cliente contrataría el depósito. Esta fase permitió comprobar la capacidad predictiva de algunas variables y analizar el efecto del desbalanceo de clases.

- **Fase 4. Dashboard final**
  Finalmente, se elaboró un dashboard en Power BI para resumir de forma visual los principales hallazgos del análisis y facilitar la interpretación de los resultados.

4. Limpieza y transformación

4.1. Exploración inicial

Antes de realizar cualquier transformación, se llevó a cabo una exploración inicial del conjunto de datos con el fin de comprender su estructura y detectar posibles problemas de calidad.

En esta primera revisión se analizaron los siguientes aspectos:

- número de filas y columnas de cada fuente de datos
- nombres de las variables disponibles
- tipos de datos iniciales
- presencia de valores nulos
- posibles registros duplicados
- variables temporales, numéricas y categóricas
- compatibilidad entre las fuentes para su posterior unión

Objetivo de esta fase

- entender cómo estaba organizado el dataset
- identificar qué variables requerían limpieza o transformación
- comprobar la coherencia entre el dataset principal y el archivo de detalle del cliente
- preparar la unión de ambas fuentes de datos

Esta revisión inicial fue necesaria para definir correctamente los pasos posteriores de limpieza y asegurar que las decisiones tomadas durante la transformación estuvieran justificadas.

4.2. Tratamiento de valores nulos

Uno de los aspectos más importantes de la fase de limpieza fue la identificación y tratamiento de los valores nulos o ausentes. Tal y como exige el proyecto, esta fase resultaba necesaria para garantizar la calidad del análisis posterior.

Proceso realizado

- se localizaron las variables que contenían valores faltantes

- se analizó si esos valores representaban realmente una ausencia de dato o si tenían un significado específico dentro del contexto de negocio
- se aplicaron distintos tratamientos según el caso:
    - imputación de valores cuando era necesario conservar la variable
    - sustitución de códigos artificiales por valores nulos reales cuando el dato no aplicaba
    - mantenimiento de algunos nulos cuando su significado era analíticamente relevante

Ejemplos relevantes del proyecto

- en variables como **pdays**, los valores faltantes no se interpretaron como un error, sino como clientes que no habían sido contactados previamente
- en variables como **age** y **euribor3m**, además del tratamiento del nulo, se generaron variables auxiliares como:
    - age_missing
    - euribor_missing

Finalidad del tratamiento de nulos:

- evitar errores en el análisis
- conservar la mayor cantidad posible de información útil
- no eliminar registros innecesariamente
- reflejar de forma más fiel la realidad del dataset

Este tratamiento permitió trabajar con un conjunto de datos más consistente y, al mismo tiempo, mantener información relevante sobre la ausencia original de ciertos valores.

4.3. Eliminación de duplicados

Otro paso fundamental en la limpieza consistió en revisar la posible existencia de registros duplicados dentro del dataset.

Proceso realizado:

- se comprobó si existían filas repetidas de forma exacta

- se revisó el papel de los identificadores únicos para detectar posibles duplicidades

- se eliminaron aquellos registros duplicados que pudieran distorsionar el análisis

Objetivo de esta fase:

- evitar que un mismo cliente o interacción apareciera varias veces sin justificación

- impedir que las métricas descriptivas, proporciones y gráficos quedaran sesgados
- asegurar que cada registro del dataset final representara una observación válida

La eliminación de duplicados contribuyó a mejorar la fiabilidad del análisis y a mantener la calidad del dataset final.

4.4. Conversión de tipos de datos

Una vez revisada la calidad general de los datos, se procedió a convertir determinadas variables a los tipos de datos más adecuados para su tratamiento y análisis.

Cambios realizados:

- conversión de variables temporales a formato fecha
- revisión de variables numéricas que inicialmente podían estar interpretadas como texto
- estandarización de variables categóricas para su análisis y visualización posterior
- adecuación de variables binarias e indicadores auxiliares

Ejemplos de variables tratadas:

- **date** y **Dt_Customer** se prepararon como variables temporales para poder extraer nueva información
- variables numéricas como ingresos, edad o indicadores económicos se revisaron para asegurar su correcto formato
- algunas variables categóricas se normalizaron para facilitar el análisis descriptivo y la representación gráfica

Finalidad de esta fase:

- permitir cálculos y transformaciones correctas
- evitar errores al generar estadísticas o gráficos
- facilitar la creación de nuevas variables derivadas
- asegurar la compatibilidad con la fase de Machine Learning posterior

La conversión de tipos fue un paso clave para poder trabajar correctamente con el dataset y sacar partido tanto a las variables originales como a las derivadas.

4.5. Creación de nuevas variables (Feature Engineer)

Una parte importante del proceso de transformación consistió en la creación de nuevas variables derivadas a partir de la información original. Este paso permitió enriquecer el dataset y generar variables más útiles para el análisis. Además, el propio proyecto valora la creación de nuevas columnas y el uso eficiente de Pandas para extraer insights.

Variables creadas:

Entre las principales variables derivadas generadas durante esta fase se encuentran:

- **was_contacted_before**
  Indicador de si el cliente había sido contactado previamente.
- **contact_weekday**
  Día de la semana en el que se realizó el contacto.
- **Customer_year** y **Customer_month**
  Año y mes de alta del cliente, extraídos de Dt_Customer.
- **Customer_tenure_years**
  Antigüedad del cliente en años.
- **tenure_at_contact_days**
  Antigüedad del cliente en días en el momento del contacto.
- **Family_size**
  Tamaño estimado de la unidad familiar.
- **Has_kid** y **Has_teens**
  Indicadores de presencia de niños o adolescentes en el hogar.
- **age_missing** y **euribor_missing**
  Variables auxiliares que indican si el valor original estaba ausente.

Finalidad del feature engineering:

- enriquecer la información disponible
- facilitar la interpretación de ciertos comportamientos del cliente
- generar variables más útiles para el análisis exploratorio
- mejorar la base del modelo predictivo posterior

La creación de estas variables permitió ampliar la capacidad analítica del dataset y estudiar relaciones que no habrían sido tan visibles utilizando solo las variables originales.

5. EDA y visualización

Una vez finalizada la fase de limpieza y transformación, se desarrolló el **Análisis Exploratorio de Datos (EDA)** con el objetivo de comprender la estructura del dataset, estudiar el comportamiento de las variables y detectar patrones relacionados con la suscripción del depósito. Esta fase constituye una parte central del proyecto, ya que

permite transformar los datos en información útil y fundamentar las conclusiones posteriores. El enunciado del proyecto exige expresamente realizar análisis descriptivo y visualización de los datos, así como presentar un informe explicativo de los resultados.

El análisis se llevó a cabo en el notebook **02_eda_analysis.ipynb**, donde se trabajó con el dataset final limpio obtenido en la fase anterior. Según la estructura del proyecto recogida en el README, en esta fase se realizaron estadísticas descriptivas, análisis de distribuciones, agrupaciones con groupby(), tablas resumen, análisis de correlación e identificación de patrones relacionados con la suscripción del depósito.

5.1. Enfoque del análisis exploratorio

El EDA se planteó con una pregunta central: **qué características presentan los clientes que sí contratan el depósito frente a los que no**. A partir de esta idea, el análisis se organizó en varios bloques para estudiar las distintas dimensiones del dataset de forma ordenada.

Principales líneas de análisis:

- **Análisis de la variable objetivo (y)**
  Se estudió la distribución de la variable que indica si el cliente suscribe o no el depósito, con el fin de conocer la proporción de clientes que convierten y evaluar el posible desbalanceo de clases.

- **Análisis de variables sociodemográficas**
  Se analizaron variables como edad, ocupación, estado civil, nivel educativo, ingresos y composición del hogar, con el fin de describir el perfil de los clientes y observar posibles diferencias entre quienes contratan y quienes no.

- **Análisis de variables relacionadas con la campaña**
  Se estudiaron variables como duración de la llamada, número de contactos realizados, canal de contacto, resultado de campañas anteriores y contacto previo, por ser especialmente relevantes en un contexto de marketing bancario.

- **Análisis de variables económicas**
  Se incluyeron indicadores como euribor3m, emp.var.rate, cons.price.idx, cons.conf.idx y nr.employed para explorar si el contexto económico podía estar asociado a la probabilidad de suscripción.

- **Análisis de correlaciones**
  Se calcularon correlaciones entre variables numéricas para identificar relaciones lineales y posibles patrones de asociación dentro del dataset.

Este enfoque permitió estudiar el problema desde una perspectiva amplia, combinando descripción general, análisis comparativo e interpretación de patrones.

5.2. Análisis descriptivo

El análisis descriptivo permitió obtener una visión general del dataset antes de profundizar en relaciones concretas entre variables. Tal y como se recoge en los criterios de evaluación del proyecto, esta parte debía incluir métricas como medias, medianas, desviaciones estándar y correlaciones.

Elementos analizados:

- dimensiones generales del dataset
- tipos de variables
- estadísticas descriptivas de variables numéricas
- distribución de frecuencias de variables categóricas
- análisis de la variable objetivo
- agrupaciones y tablas resumen por categorías relevantes

A través de este análisis se identificó, entre otros aspectos, que la variable objetivo presenta un comportamiento desbalanceado, ya que la contratación del depósito es claramente minoritaria frente a la no contratación. Este hallazgo fue importante porque condicionó tanto la interpretación de los resultados del EDA como la fase posterior de Machine Learning.

Asimismo, el análisis descriptivo permitió detectar qué variables parecían mostrar diferencias más marcadas entre ambos grupos de clientes, especialmente aquellas relacionadas con la interacción comercial y con el historial previo de contacto.

5.3. Visualización de los datos

La visualización fue una parte esencial del proyecto, ya que permitió representar de forma clara las distribuciones, relaciones y patrones detectados en el análisis. El enunciado del proyecto destaca la necesidad de crear gráficos claros y efectivos utilizando librerías como Matplotlib y Seaborn para ilustrar relaciones relevantes en los datos.

Tipos de visualizaciones empleadas:

- **Histogramas**
  Se utilizaron para analizar la distribución de variables numéricas como edad, ingresos, duración de llamada, número de contactos o variables económicas.
- **Countplots y gráficos de barras**
  Se emplearon para estudiar la frecuencia de variables categóricas como ocupación, estado civil, nivel educativo, canal de contacto o resultado de campañas anteriores.
- **Boxplots**
  Permitieron comparar distribuciones de variables numéricas frente a la variable objetivo, por ejemplo para observar diferencias en duración de llamada, ingresos o antigüedad entre clientes que sí contratan y clientes que no.
- **Gráficos circulares o de proporción**
  Se utilizaron como apoyo visual en algunas variables categóricas,

especialmente para mostrar la distribución de la variable objetivo o de categorías simples.

- **Heatmap de correlación**
  Se empleó para visualizar la relación entre variables numéricas y detectar asociaciones destacables dentro del conjunto de datos.

Estas visualizaciones no se utilizaron únicamente como apoyo estético, sino como herramienta para reforzar la interpretación del análisis y justificar los hallazgos detectados.

5.4. Principales hallazgos del EDA

- la contratación del depósito representa una parte minoritaria del total de clientes, lo que confirma el desbalanceo de la variable objetivo

- las variables más relacionadas con la conversión parecen estar vinculadas a la **interacción comercial**, especialmente la duración de la llamada y el historial de contacto previo

- el resultado de campañas anteriores y el hecho de haber sido contactado previamente muestran una asociación clara con la probabilidad de suscripción

- el canal de contacto presenta diferencias relevantes, sugiriendo distinta eficacia según la vía utilizada

- las variables económicas parecen desempeñar un papel complementario en la explicación del comportamiento del cliente

- las variables sociodemográficas ayudan a perfilar al cliente, aunque en general parecen tener un peso menor que las variables relacionadas con la campaña

Estos hallazgos sirvieron de base para responder a la pregunta principal del proyecto y también para seleccionar variables relevantes en la fase posterior de Machine Learning.

5.5. Relación entre EDA y dashboard final

Los resultados obtenidos en el EDA se tomaron como base para el diseño del dashboard final en **Power BI**, donde se sintetizaron visualmente las métricas y patrones más importantes del análisis. Según el README del proyecto, el dashboard incluye elementos como la tasa de conversión, la distribución de clientes que contratan frente a los que no, las contrataciones por canal de contacto, las contrataciones por ocupación, la relación entre el Euribor y el comportamiento del cliente, y una línea temporal de contrataciones.

De este modo, la fase de visualización no se limitó a los gráficos del notebook, sino que se amplió con una representación más sintética e interactiva orientada a resumir los principales resultados del análisis de forma clara y accesible.

6. Modelo de Machine Learning

Como ampliación del proyecto de análisis exploratorio, se desarrolló un modelo sencillo de **Machine Learning** con el objetivo de comprobar si las variables del dataset permitían predecir la suscripción del depósito por parte del cliente. Esta fase no sustituye al análisis exploratorio, sino que lo complementa, ya que permite pasar de la descripción de patrones a una primera aproximación predictiva

6.1. Objetivo del modelo

El objetivo principal del modelo fue **predecir si un cliente contrataría o no el depósito**, utilizando como variable objetivo y. Esta variable indica si el cliente suscribe el producto ofrecido por el banco, y constituye la referencia principal tanto del EDA como de la fase predictiva. El propósito de esta etapa fue analizar si algunas de las variables estudiadas previamente tenían capacidad para anticipar el comportamiento del cliente.

Este modelo se planteó como una aproximación sencilla y comprensible, adecuada al nivel del proyecto, con dos finalidades principales:

- comprobar si existía una relación predictiva entre las variables del dataset y la suscripción del depósito
- complementar el análisis exploratorio con una perspectiva básica de clasificación supervisada

Por tanto, no se buscó construir un modelo complejo o de máxima precisión, sino incorporar una fase de Machine Learning coherente con el resto del trabajo realizado.

6.2. Selección de variables

Para el modelo se seleccionó un conjunto reducido de variables numéricas relacionadas con el cliente, la campaña y el contexto económico. Esta selección se realizó de forma sencilla y guiada por los resultados observados en el EDA, donde algunas variables mostraban una relación más clara con la conversión. Según el planteamiento recogido en el proyecto, la fase de Machine Learning parte precisamente de la selección de variables relevantes antes del entrenamiento del modelo.

```python
# Seleccionar variables para el modelo
features = [
    "age",
    "duration",
    "campaign",
    "previous",
    "euribor3m",
    "emp.var.rate",
    "cons.price.idx",
    "cons.conf.idx"
]

X = data[features]
y = data["y"]
```

Entre las variables utilizadas se incluyeron indicadores como:

- edad del cliente
- duración de la llamada
- número de contactos realizados durante la campaña
- número de contactos previos
- Euribor a tres meses
- tasa de variación del empleo
- índice de precios al consumidor
- índice de confianza del consumidor

La elección de estas variables respondió a dos criterios:

- incluir variables con valor explicativo potencial, observadas durante el análisis exploratorio
- mantener un modelo sencillo y fácil de interpretar, evitando una complejidad innecesaria

De esta forma, el modelo se construyó sobre una base reducida pero representativa de distintos bloques del dataset: perfil del cliente, dinámica comercial y contexto económico.

6.3. División del dataset (train/test)

Una vez definidas las variables de entrada, el dataset se dividió en dos subconjuntos:

- **conjunto de entrenamiento**, utilizado para ajustar el modelo
- **conjunto de prueba**, utilizado para evaluar su comportamiento sobre datos no vistos previamente

Tal y como se aplicó en el proyecto, se utilizó una división estándar del **80% para entrenamiento y 20% para prueba**, lo que permitió entrenar el modelo con la mayor parte de los datos y reservar una muestra independiente para su evaluación. Este procedimiento es habitual en problemas de clasificación y evita medir el rendimiento del modelo únicamente sobre los mismos datos con los que ha sido entrenado.

Además, antes del entrenamiento se realizó el **escalado de las variables numéricas**, paso especialmente recomendable en modelos como la regresión logística, ya que ayuda a trabajar con variables expresadas en magnitudes diferentes y favorece una mejor estabilidad del modelo.

```
# Separar datos de entrenamiento y test
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42
)
```
[6]

```
# Escalar variables
scaler = StandardScaler()

X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```
[7]

6.4. Entrenamiento del modelo

El modelo seleccionado fue una **Regresión Logística**, por tratarse de un algoritmo sencillo, interpretable y adecuado para problemas de clasificación binaria como este, donde el objetivo es predecir si un cliente contratará (1) o no contratará (0) el depósito. El README del proyecto especifica que esta fue la técnica utilizada en la fase de Machine Learning.

El entrenamiento se realizó sobre el conjunto de entrenamiento previamente escalado. En una primera aproximación se construyó un modelo básico, y posteriormente se aplicó una mejora mediante el parámetro:

```
# Crear y entrenar al modelo
model = LogisticRegression(class_weight="balanced", max_iter=1000)

model.fit(X_train_scaled, y_train)
```

[24]

```
LogisticRegression
▸ Parameters
```

con el fin de tratar el **desbalanceo de la variable objetivo**, ya que durante el EDA se había comprobado que la contratación del depósito era claramente minoritaria. Esta mejora también aparece recogida de forma explícita en el README del proyecto.

La incorporación de este ajuste permitió que el modelo prestara más atención a la clase minoritaria, es decir, a los clientes que sí contratan el depósito, algo especialmente importante en un contexto de marketing.

6.5. Evaluación del modelo

La evaluación del modelo se llevó a cabo mediante varias métricas de clasificación, siguiendo el enfoque descrito en el README del proyecto:

Accuracy:

El modelo de **regresión logística balanceado** obtiene una **accuracy de 0,84**, lo que significa que clasifica correctamente aproximadamente el **84% de los casos**. Aunque este valor es algo inferior al de un modelo centrado en la clase mayoritaria, en este caso es más útil porque mejora la detección de los clientes que sí contratarían el depósito.

Classification report:

En la **clase 0** (clientes que no contratan el depósito), el modelo obtiene:

- **precision = 0,98**
- **recall = 0,84**
- **f1-score = 0,90**

Esto indica que el modelo sigue funcionando bien para identificar a los clientes que no contratan.

En la **clase 1** (clientes que sí contratan el depósito), el modelo obtiene:

- **precision = 0,41**
- **recall = 0,85**
- **f1-score = 0,55**

El dato más importante aquí es el **recall de 0,85**, ya que significa que el modelo consigue detectar correctamente el **85% de los clientes que realmente sí contratarían el depósito**. Esto es especialmente relevante en un contexto de marketing, donde interesa identificar al mayor número posible de clientes potencialmente interesados.

La precisión de la clase 1 es más baja (**0,41**), lo que significa que no todos los clientes que el modelo predice como posibles contratantes acabarían contratando realmente el depósito. Aun así, este comportamiento es habitual cuando se prioriza la detección de la clase minoritaria.

Matriz de confusión:

La matriz de confusión muestra lo siguiente:

- **6363** clientes no contrataron el depósito y el modelo lo predijo correctamente.
- **835** clientes sí contrataron el depósito y el modelo también lo predijo correctamente.
- **1211** clientes no contrataron, pero el modelo pensó que sí lo harían.
- **142** clientes sí contrataron, pero el modelo no logró detectarlos.

Estos resultados muestran que el modelo **detecta muy bien a los clientes que sí contratan**, ya que deja escapar relativamente pocos casos positivos (**142**). A cambio, genera un número mayor de falsos positivos (**1211**), es decir, clientes que parecen tener probabilidad de contratar pero finalmente no lo hacen.

Desde el punto de vista del negocio, este comportamiento puede ser aceptable, ya que en campañas de marketing suele ser preferible **contactar a más clientes potenciales** antes que dejar fuera a muchos clientes que sí podrían contratar.

Predicción estimada de clientes que contratarían:

El modelo predice que, de los **8551 clientes analizados en el conjunto de prueba**, aproximadamente **2046 contratarían el depósito**, lo que supone una **tasa estimada de contratación del 23,93%**.

A partir de esta proporción, se puede hacer una estimación sencilla para campañas futuras. Por ejemplo, si en una campaña similar se contactara a **10.000 clientes**, el modelo estimaría que aproximadamente **2393 clientes podrían contratar el depósito**.

6.6. *Interpretación de resultados*

En conclusión, el modelo obtiene una **accuracy del 84%**, clasificando correctamente la mayoría de los casos. Su punto fuerte es que detecta muy bien a los clientes que sí contratarían el depósito, con un **recall del 85% en la clase 1**. La matriz de confusión muestra que el modelo acierta con **835 clientes que sí contratan** y solo deja escapar **142**, aunque a cambio genera más falsos positivos. En total, predice que **2046 de 8551 clientes** podrían contratar el depósito, lo que equivale a una **tasa estimada del 23,93%**. Esto sugiere que el modelo puede ser útil para identificar clientes potenciales en futuras campañas de marketing.

7. Dashboard en Power BI

7.1. Objetivo del dashboard

El objetivo del dashboard es **presentar de forma visual, clara e interactiva los principales resultados obtenidos en el análisis del dataset de campañas de marketing bancario**. A través de este panel, se busca resumir la información más relevante sobre la suscripción del depósito y facilitar la identificación de patrones relacionados con el comportamiento de los clientes.

En concreto, el dashboard permite:

- visualizar el volumen total de clientes analizados
- conocer cuántos clientes contrataron el depósito y cuál fue la tasa de contratación
- comparar la suscripción según variables relevantes, como el canal de contacto, la ocupación o el mes de interacción
- explorar la información mediante filtros, como educación, estado civil o rango temporal
- complementar el análisis con una visualización de la relación entre variables económicas y características del cliente

7.2. *Visualización*

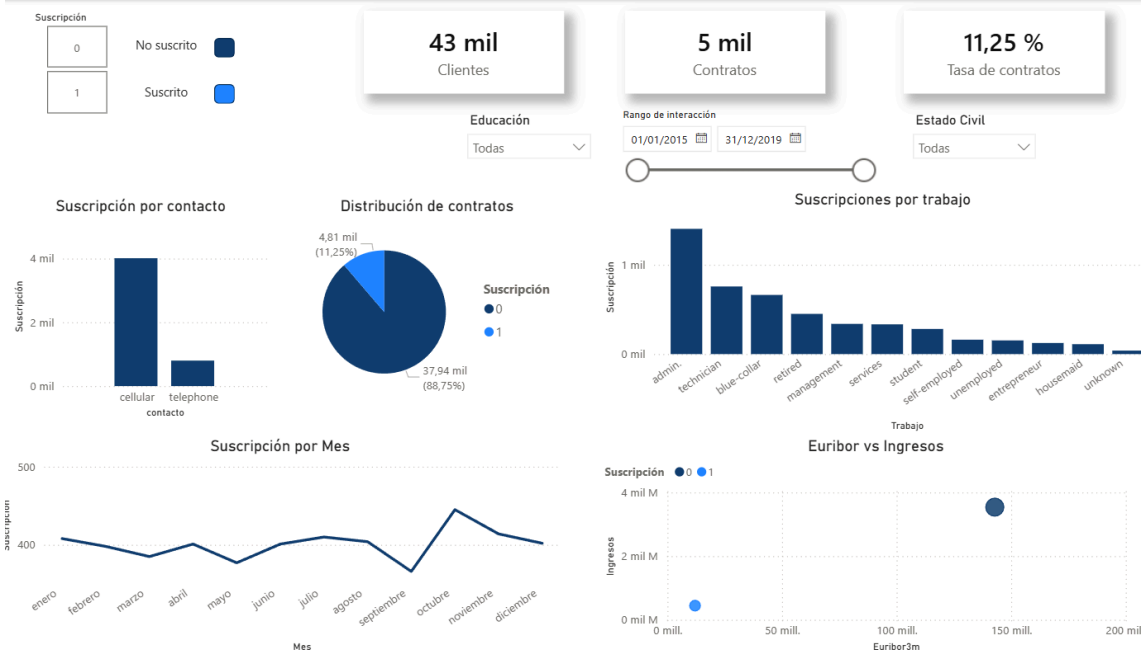

7.3. *Interpretación de los resultados*

En primer lugar, se observa que el conjunto analizado está formado por aproximadamente **43 mil clientes**, de los cuales alrededor de **5 mil contrataron el depósito**, lo que supone una **tasa de contratación del 11,25%**. Este dato confirma que la suscripción del producto es claramente minoritaria, algo que ya se había detectado en el análisis exploratorio.

En relación con el **canal de contacto**, el gráfico de suscripción por contacto muestra que el canal **cellular** concentra un volumen mucho mayor de contrataciones que **telephone**. Esto sugiere que el contacto a través de móvil resulta más efectivo o, al menos, está asociado a una mayor conversión.

La **distribución de contratos** refuerza la idea del desbalanceo de la variable objetivo, ya que la mayor parte de los clientes no suscriben el depósito, mientras que solo una pequeña proporción sí lo hace. Esta diferencia visual permite entender rápidamente por qué el problema resulta más complejo desde el punto de vista predictivo.

En cuanto a la **ocupación**, el gráfico de suscripciones por trabajo muestra que las categorías con mayor número de contrataciones son **admin.**, **technician** y **blue-collar**. Esto indica que determinados perfiles profesionales concentran un mayor volumen de conversiones, aunque este resultado también puede estar influido por el peso de cada categoría dentro del conjunto total de clientes.

La **línea temporal de suscripción por mes** muestra cierta variación a lo largo del año, aunque sin cambios extremadamente bruscos. Se aprecia un aumento destacado en **octubre**, mientras que meses como **septiembre** presentan valores más bajos. Esto sugiere que puede existir cierta estacionalidad o variación temporal en la respuesta de los clientes a la campaña.

Por último, el gráfico de dispersión **Euribor vs Ingresos** incorpora una perspectiva complementaria, al relacionar una variable económica con una característica del

cliente y diferenciando según la suscripción. Aunque su interpretación es más exploratoria, ayuda a visualizar posibles diferencias entre grupos y a enriquecer el análisis general.

En conjunto, el dashboard confirma los principales hallazgos del proyecto: la contratación del depósito es reducida, el canal de contacto influye en la conversión, algunas ocupaciones concentran más suscripciones y existen variaciones temporales en el comportamiento de la campaña. Además, permite resumir de forma visual e interactiva los resultados más importantes obtenidos en las fases anteriores del proyecto

8. Resultados e insights clave

8.1. Hallazgos principales

- **La contratación del depósito es minoritaria**, con una tasa de suscripción aproximada del **11,25%**, lo que confirma que la variable objetivo está desbalanceada.

- **Las variables más relevantes son las relacionadas con la campaña**, especialmente la **duración de la llamada**, el **historial de contacto previo** y el **resultado de campañas anteriores**.

- **El canal de contacto influye en la conversión**, ya que el contacto por **móvil** muestra un mayor número de contrataciones que el teléfono tradicional.

- **Las variables sociodemográficas** como edad, ocupación o nivel educativo ayudan a perfilar al cliente, pero en general tienen **menos peso que las variables de interacción comercial**.

- **El contexto económico** aporta información complementaria, aunque su influencia parece menor que la de las variables de campaña.

- **El modelo de Machine Learning confirma los patrones observados en el EDA**, mostrando que las variables seleccionadas tienen capacidad para predecir, en parte, la contratación del depósito.

- **El dashboard en Power BI permite resumir visualmente los principales resultados**, facilitando la identificación de patrones de conversión, perfiles de clientes y evolución temporal de las suscripciones.

8.2. Factores que influyen en la contratación del depósito

- **Duración de la llamada**

  Los clientes que contratan el depósito suelen tener llamadas más largas, lo que sugiere una mayor interacción e interés durante el contacto comercial.

- **Historial de contacto previo**

  Haber sido contactado anteriormente y haber tenido resultados positivos en

campañas previas aumenta la probabilidad de contratación.

- **Canal de contacto**
  El contacto a través de **móvil** muestra mejores resultados que el teléfono tradicional, por lo que parece ser un canal más eficaz.

- **Número de contactos realizados**
  La frecuencia de contacto también influye, ya que forma parte de la dinámica comercial de la campaña.

- **Perfil profesional del cliente**
  Algunas ocupaciones concentran un mayor número de contrataciones, lo que indica que ciertos perfiles son más receptivos al producto.

- **Contexto económico**
  Variables como el **Euribor** y otros indicadores económicos parecen tener una influencia complementaria en la predisposición del cliente a contratar.

8.3. Posibles aplicaciones prácticas

- **Mejorar la segmentación de clientes**
  El banco puede identificar perfiles con mayor probabilidad de contratación y dirigir las campañas a esos segmentos.

- **Optimizar el canal de contacto**
  Dado que el móvil muestra mejores resultados, se podría priorizar este canal en futuras campañas.

- **Ajustar la estrategia comercial**
  Conocer la importancia del historial previo y del resultado de campañas anteriores permite diseñar campañas más personalizadas.

- **Apoyar la toma de decisiones con modelos predictivos**
  El modelo de Machine Learning puede utilizarse como apoyo para detectar clientes potenciales antes de lanzar nuevas campañas.

- **Diseñar dashboards de seguimiento**
  El dashboard en Power BI facilita el control de métricas clave, la evolución temporal de las contrataciones y la identificación de patrones de conversión.

- **Aumentar la eficiencia de futuras campañas**
  En conjunto, estos hallazgos permiten enfocar mejor los recursos comerciales y aumentar la probabilidad de éxito de las campañas de marketing directo.

9. Conclusión

Este proyecto ha permitido desarrollar un análisis completo de campañas de marketing bancario, desde la limpieza y transformación de los datos hasta la interpretación final de los resultados. El EDA mostró que la contratación del depósito es minoritaria y que los factores más relacionados con la conversión son, sobre todo, los vinculados a la interacción comercial, como la duración de la llamada, el historial de contacto previo y el canal de contacto.

Además, el modelo de Machine Learning confirmó que varias de estas variables tienen capacidad predictiva, mientras que el dashboard en Power BI permitió resumir de forma visual los principales hallazgos. En conjunto, el proyecto ha servido para aplicar de forma práctica un flujo completo de análisis de datos y para identificar factores útiles en la mejora de futuras campañas de marketing bancario.

10. Anexos

10.1. Fragmentos de código relevantes

```python
class BankMarketingEDA:
    """
    Clase para realizar un análisis exploratorio básico del dataset de marketing bancario.
    """

    def __init__(self, file_path: str):
        self.file_path = file_path
        self.data = None

    def load_data(self):
        """
        Carga el dataset con control de errores.
        """
        try:
            self.data = pd.read_csv(self.file_path)

            if self.data.empty:
                raise ValueError("El archivo CSV está vacío.")

            print("Dataset cargado correctamente.")
            print(f"Filas: {self.data.shape[0]}")
            print(f"Columnas: {self.data.shape[1]}")

        except FileNotFoundError:
            print(f"Error: no se encontró el archivo '{self.file_path}'.")

        except pd.errors.EmptyDataError:
            print("Error: el archivo está vacío o no contiene datos válidos.")

        except pd.errors.ParserError:
            print("Error: hubo un problema al interpretar el archivo CSV.")

        except Exception as e:
            print(f"Error inesperado al cargar los datos: {e}")
```

Esta clase se crea para **organizar mejor el código del EDA** y agrupar en una sola estructura tareas como la carga de datos, el análisis general y la generación de gráficos. Su objetivo es hacer el código **más ordenado, reutilizable y fácil de mantener**. Además, permite incorporar **control de errores con try...except** y dar al proyecto una estructura más profesional.

11. Bibliografía y recursos utilizados

- Módulos de Python, Python for data y Regresión y Clasificación de Hack(io) by The Power
- Documentación oficial de Pandas: https://pandas.pydata.org/docs/user_guide/index.html
- Documentación oficial de Matplotly: https://matplotlib.org/stable/users/index

  https://seaborn.pydata.org/tutorial.html